#### **Datasciences & IA**

Christophe Rodrigues

## Rappel - les différents types de recherche

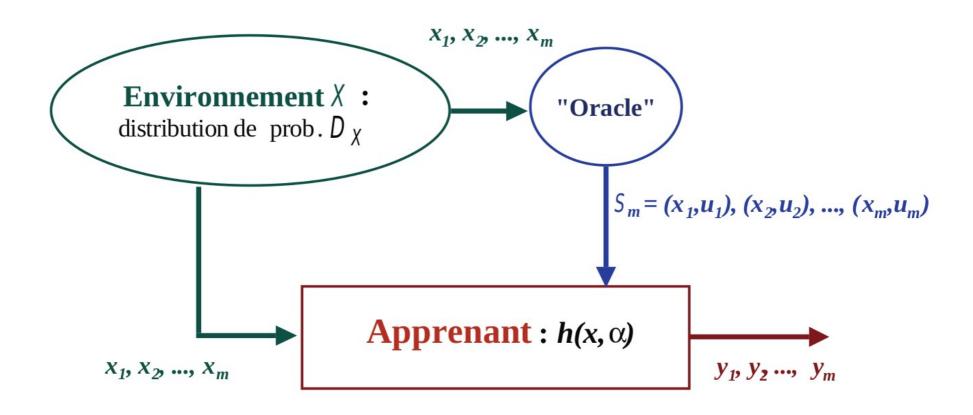
- Algorithme génétique
- Apriori A\*
- Programmation par contrainte
- En présence d'un adversaire
- Recherche d'hypothèses dans un espace d'exemples :

**Apprentissage Automatique (Machine Learning)** 

#### Plan du cours

- Définition de l'apprentissage
- Evaluation de l'apprentissage
- Exemple de méthode supervisée (kNN)
- Exemple de méthode non-supervisée (DBSCAN)
- Historique de l'apprentissage

#### **Apprentissage par induction**

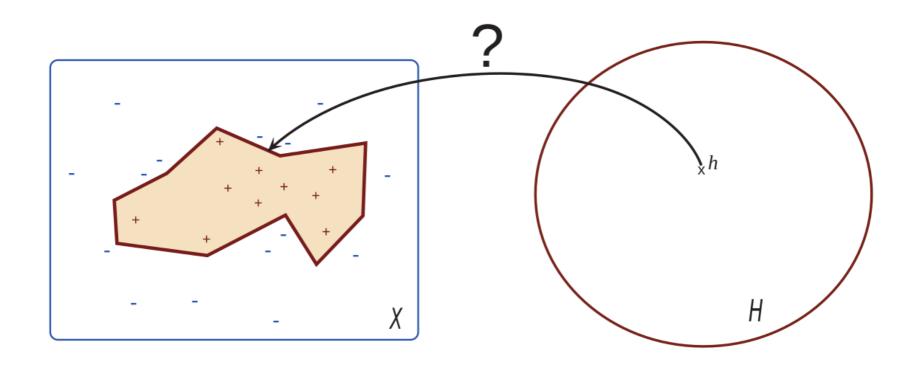


#### Définition de l'apprentissage

Espace des exemples : X

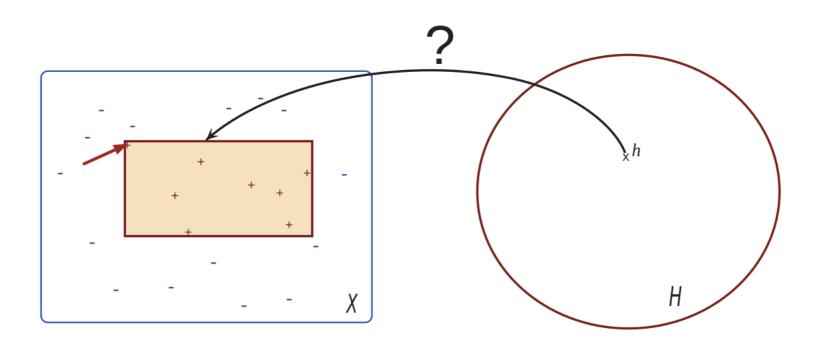
Espace des hypothèses : H

On Cherche une hypothèse h capable d'expliquer au mieux les exemples



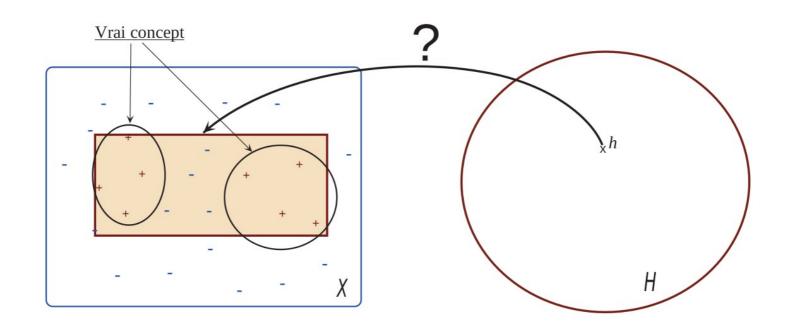
## Choix d'un langage d'hypothèses

Exemple des hypothèses « rectangles » : Définition d'un langage

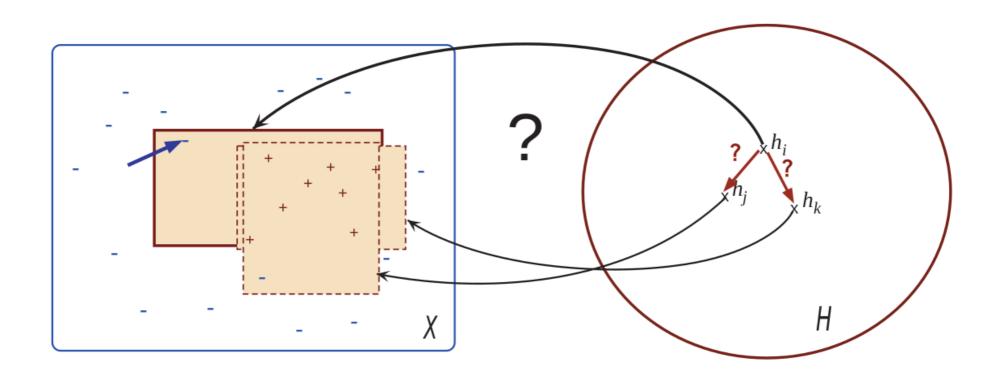


## Expressivité d'un langage

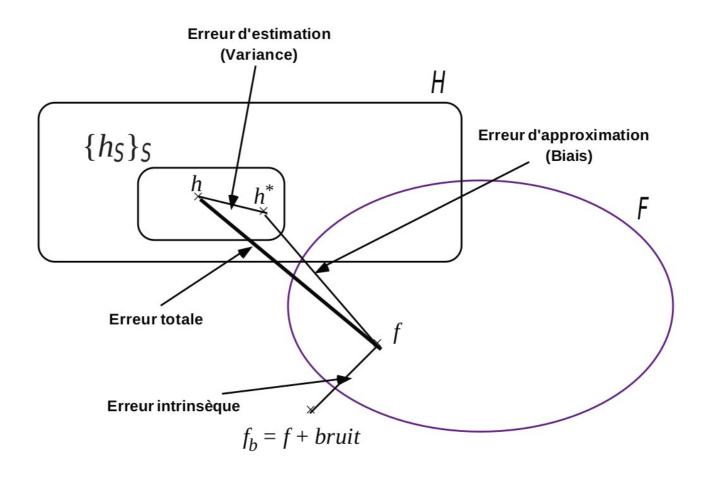
Impossible dans ce cas avec une hypothèse « rectangle » de ne pas faire d'erreurs de prédiction



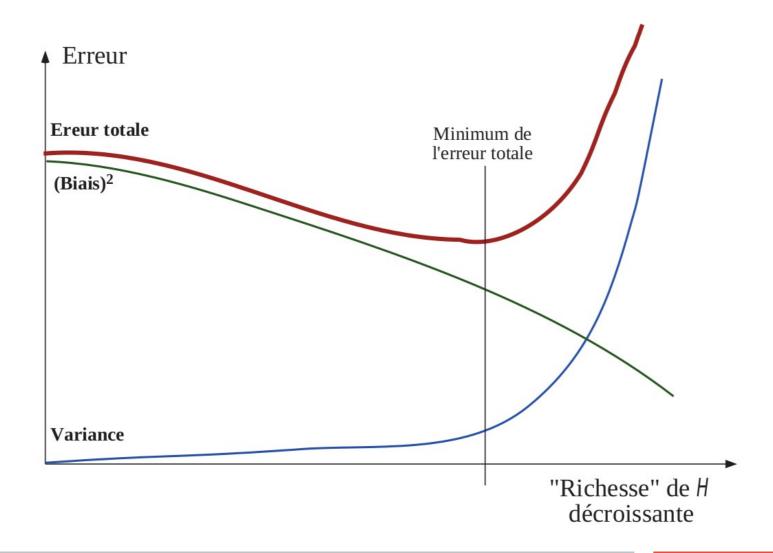
## Exploration de l'espace des hypothèses



## Les erreurs de l'apprentissage



## Le compromis Biais/Variance



#### Apprentissage automatique (ML)

#### Apprentissage supervisé

- Classification (prédire une catégorie)
- Régression (prédire une valeur continue)

#### Apprentissage non-supervisé

Regroupement (partitionner les exemples)

#### Evaluation de l'apprentissage

- Comment tester si une hypothèse et assez générale et éviter le surapprentissage ?
- · Séparation des données en deux groupes :
  - Données d'apprentissage
  - Données d'évaluations
  - (voir trois) Données de validations
- · Répartition des données par tirage aléatoire

#### **Evaluation de l'apprentissage - Erreur**

#### Dans le cas binaire de l'exemple :

Matrice de confusion

	·+'	<b>،</b> _ ,
·+'	Vrais positifs	Faux positifs
6_9	Faux négatifs	Vrais négatifs

Généralisable à plusieurs classes

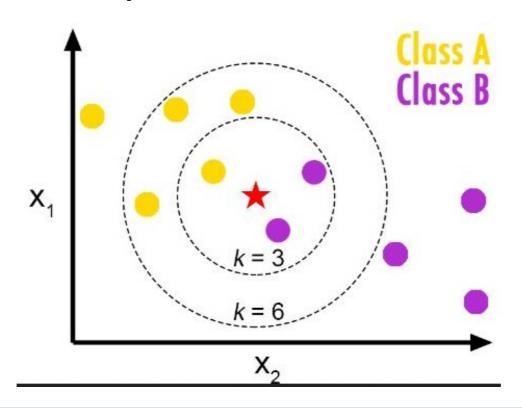
#### Dans le cas continu pour N exemples :

MSE = 
$$\frac{1}{N} \sum_{i=1}^{N} (y_i - \hat{y}_i)^2$$

## **Exemple supervisé - k plus proches voisins**

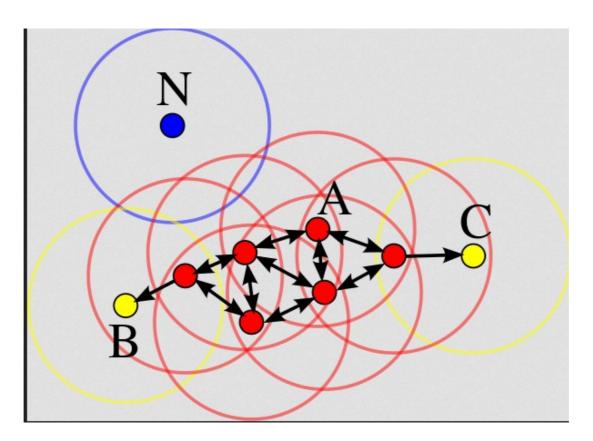
Repose sur la densité

Généralisable à plusieurs dimensions, plusieurs classes ou en régression Dépend fortement du paramètre k

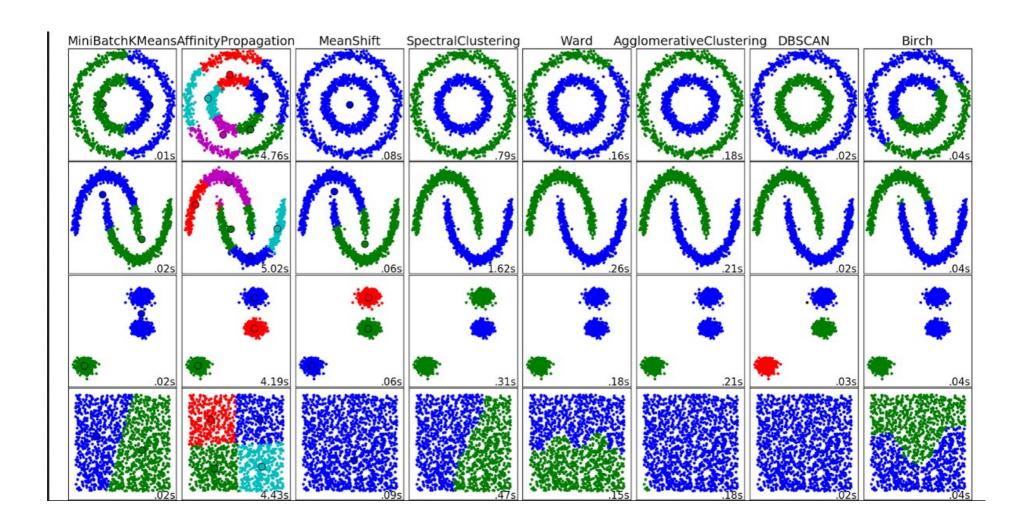


## **Exemple non-supervisé - DBSCAN**

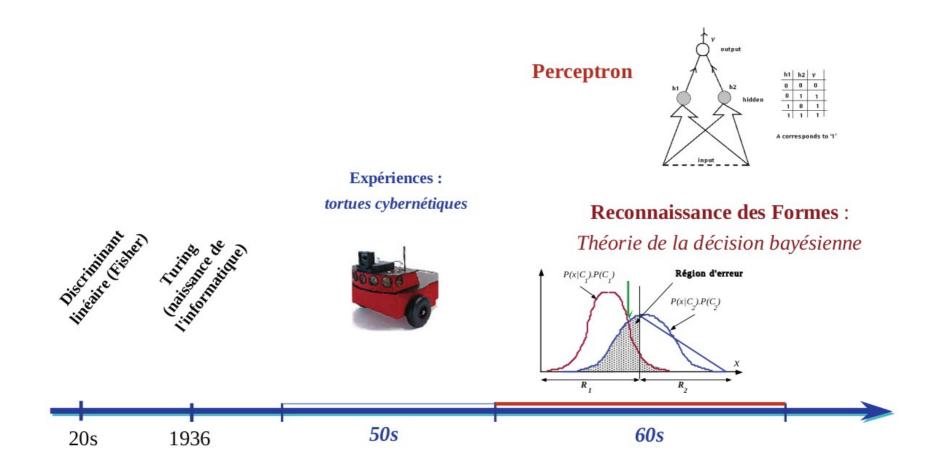
Deux paramètres : epsilon (taille du cercle) et MinPts (nombre minimal de points par cercle pour créer un cluster)



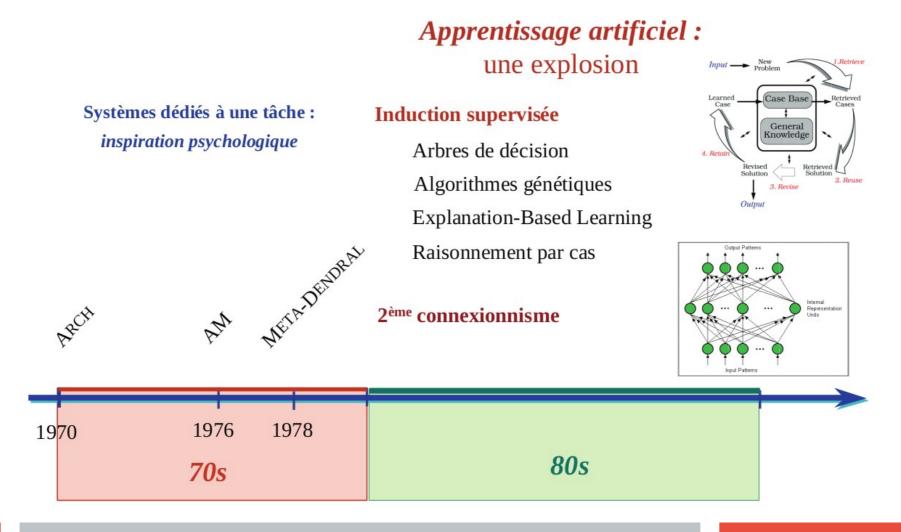
### Comparaison de méthodes de clustering



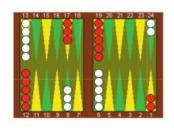
# Évolution de l'apprentissage automatique



# Évolution de l'apprentissage automatique

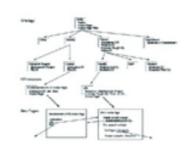


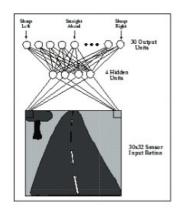
# Évolution de l'apprentissage automatique



#### Apprentissage artificiel:

une théorisation et une mise à l'épreuve





régite de Vappil

#### **Nouvelles méthodes:**

- SVMs

- Boosting

Data mining
Text mining

